



**FACULTAD
DE INGENIERIA**

Universidad de Buenos Aires

Series Temporales

1B 2024

Sergio Hinojosa


Dataset

Ventas al mercado interno de Producción Nacional de Vino en miles de hectolitros

Frecuencia de actualización: Mensual

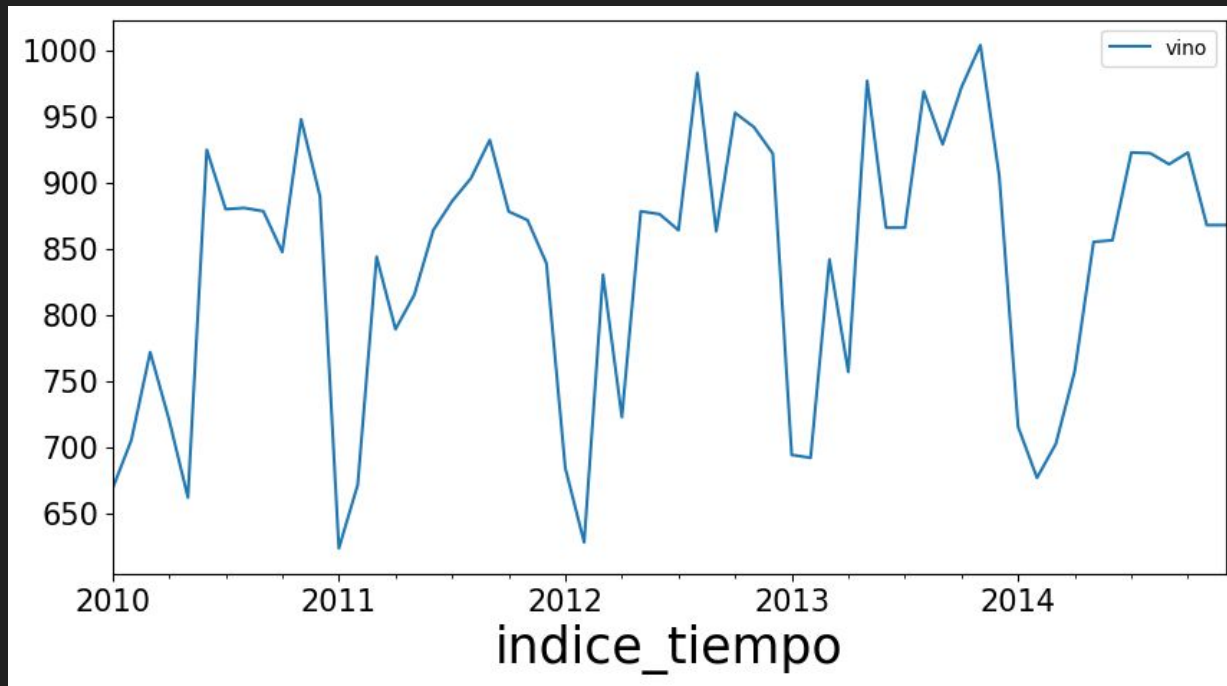
Unidades: Miles de hectolitros

322 muestras



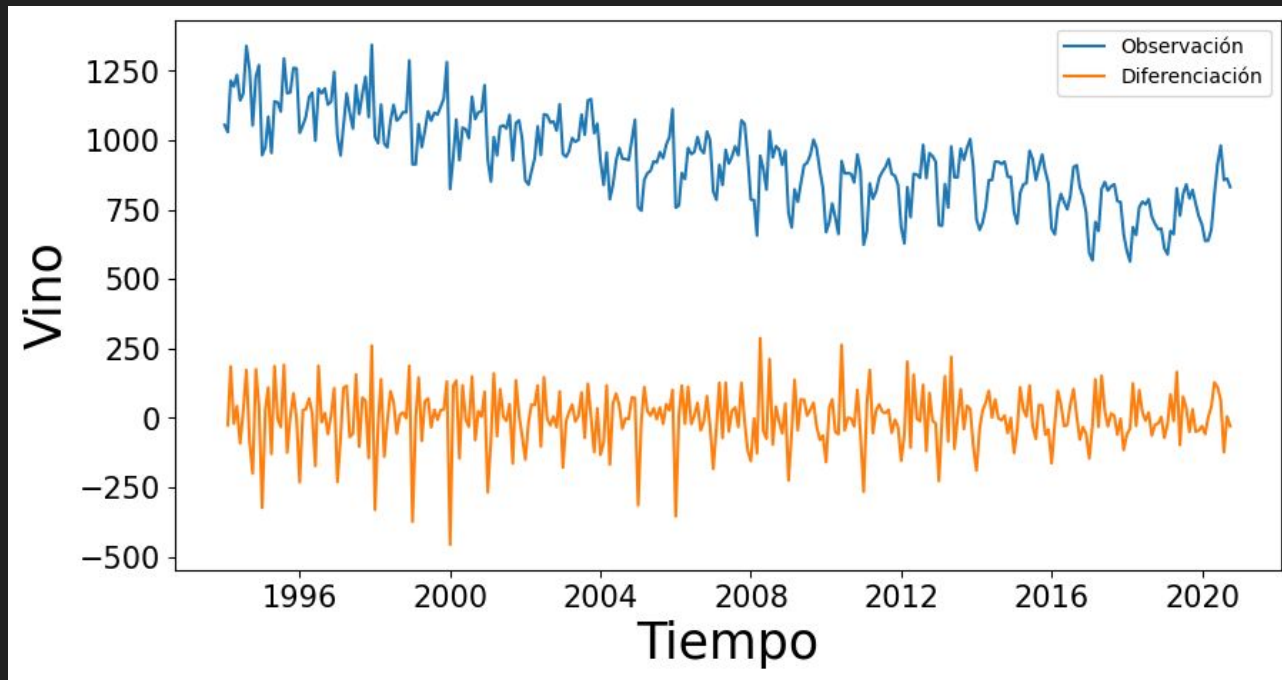
Dataset

Intervalo de 5 años




Preprocesamiento

Diferenciación



Preprocesamiento

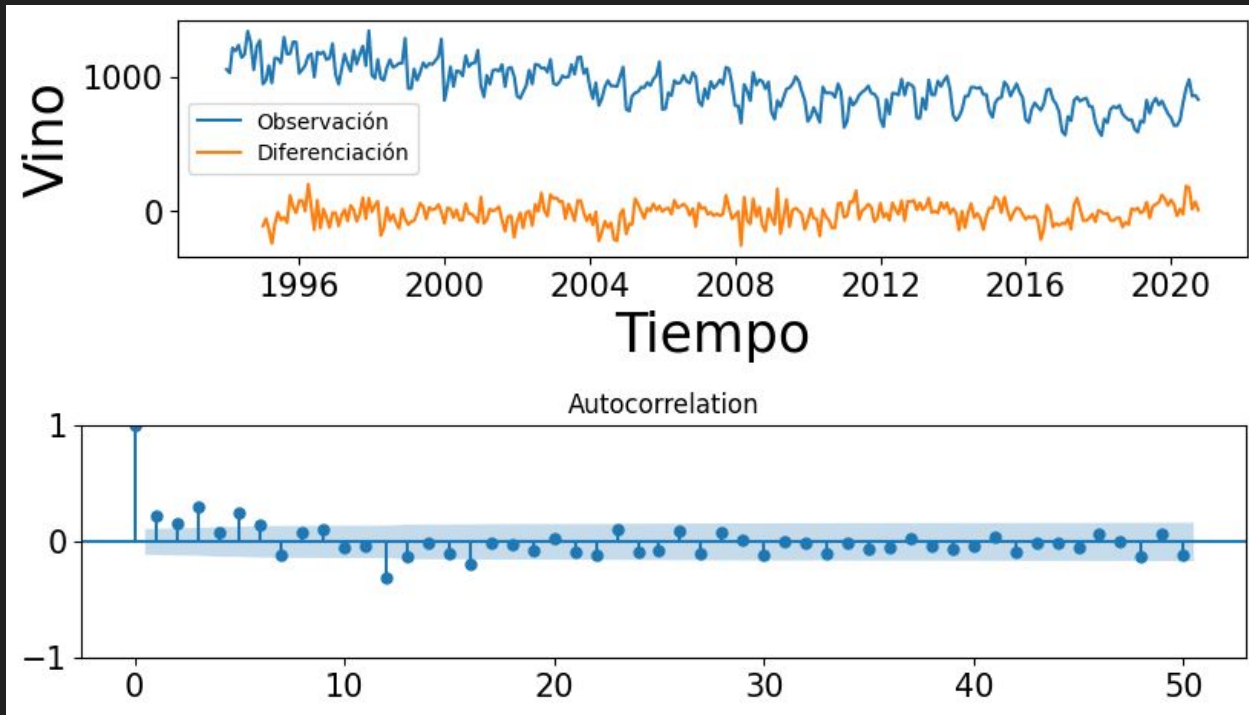
Diferenciación



Preprocesamiento

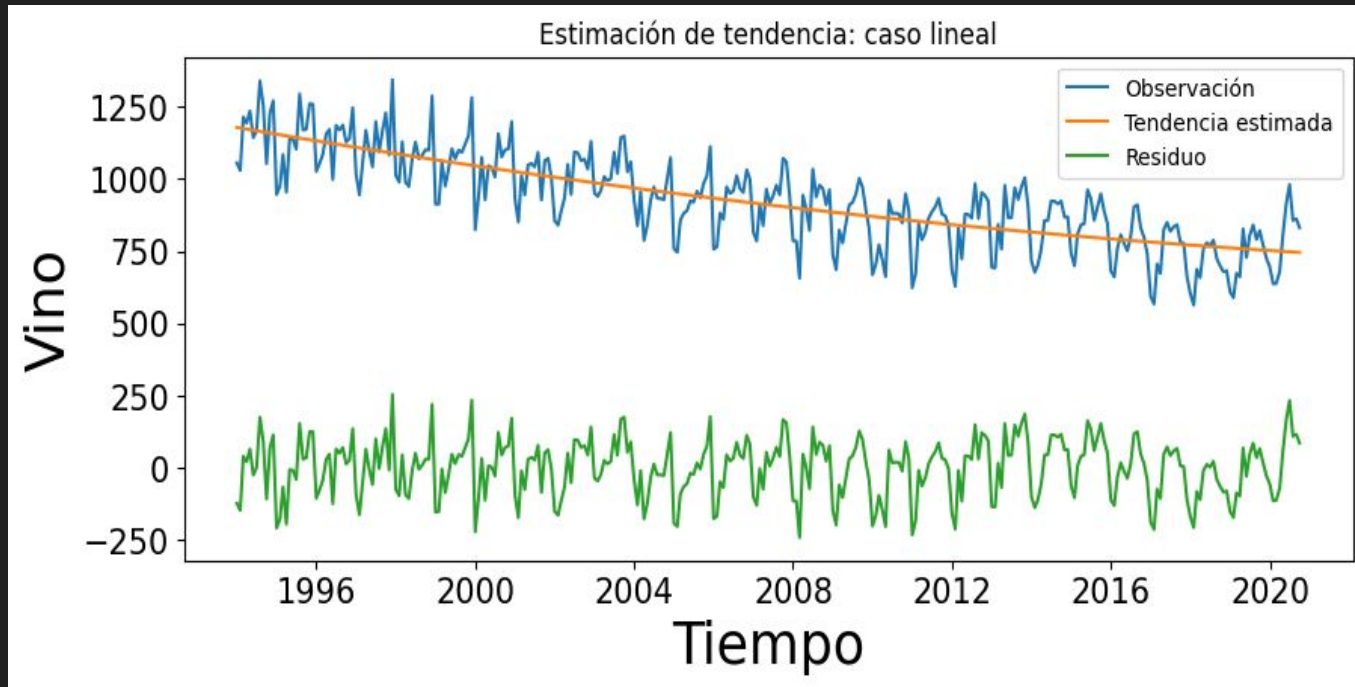
Diferenciación

a 12 pasos




Preprocesamiento

Tendencia lineal



Preprocesamiento

Tendencia lineal



Estacionareidad

Test de Dickey-Fuller

Estadístico	-4.318932
p-valor	0.000412
Lags usados	17.000000
Observaciones usadas	304.000000
Valor del umbral (1%)	-3.452045
Valor del umbral (5%)	-2.871095
Valor del umbral (10%)	-2.571861

El estadístico es menor que los 3 umbrales, por lo tanto puedo rechazar la hipótesis nula. Por otro lado, el p-valor es muy chico.
Según este test la serie diferenciada es ESTACIONARIA.

Estacionareidad

Test KPSS

Estadístico	0.040966
p-valor	0.100000
Lags usados	7.000000
Valor del umbral (10%)	0.347000
Valor del umbral (5%)	0.463000
Valor del umbral (2.5%)	0.574000
Valor del umbral (1%)	0.739000

En este caso el p-valor no es significativamente chico por lo que no puedo rechazar el test, puedo asumir entonces que la serie es ESTACIONARIA.

Ambos test dan indicio que la serie es ESTACIONARIA.

Modelo ARIMA

$p = 1, q = 2, d = 0$


Log Likelihood -1900.638

AIC 3811.276

BIC 3830.148


Ljung-Box (L1) (Q) 0.03

Prob(Q) 0.86




Modelo ARIMA

Predicción



Análisis espectral



Modelo SARIMA

$p = 1, d = 0, q = 2$

$P = 3, D = 1, Q = 3, S = 12$


Log Likelihood -1700.961

AIC 3421.922

BIC 3459.288

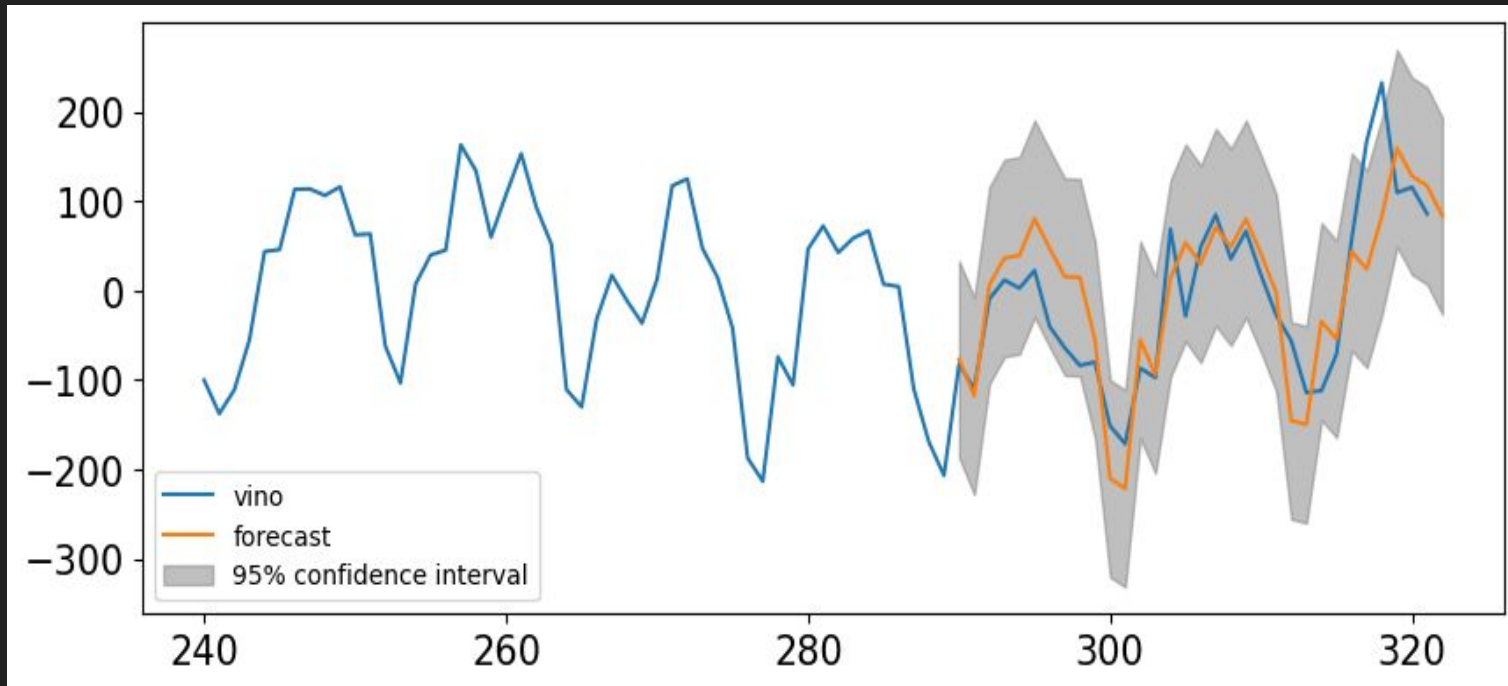
Ljung-Box (L1) (Q) 0.02

Prob(Q) 0.89



Modelo ARIMA

Predicción

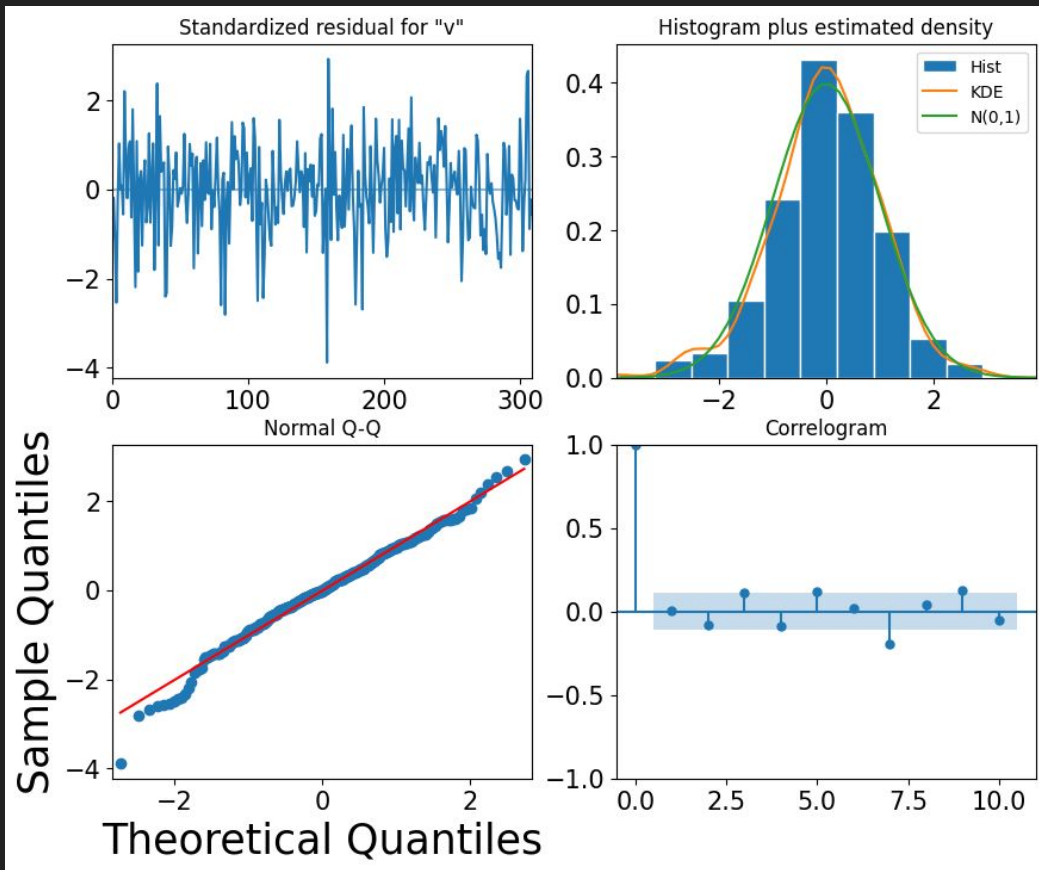


Modelo SARIMA

Análisis de residuos

Ljung-Box (L1) (Q) 0.02

Prob(Q) 0.89



Modelo SARIMA

```
# Set parameter range
p = range(1,4)
q = range(1,4)
d = range(0,2)
s = [12]

pdq = list(product(p, d, q))
seasonal_pdq = list(product(p, d, q, s))
# Create SARIMA model for each order and seasonal order
aics = []
for order in pdq:
    for seasonal_order in seasonal_pdq:
        try:
            model = ARIMA(serie, order=order, seasonal_order=seasonal_order)
            results = model.fit()
            if results.llf != 0:
                aics.append((order, seasonal_order, results.aic))
        except:
            print('SARIMA{},{} - Skipped'.format(order, seasonal_order))

# Check for smallest AIC
aics.sort(key=lambda x: x[2])
```

Modelo SARIMA

$p = 1, d = 0, q = 2$

$P = 1, D = 1, Q = 2, S = 12$

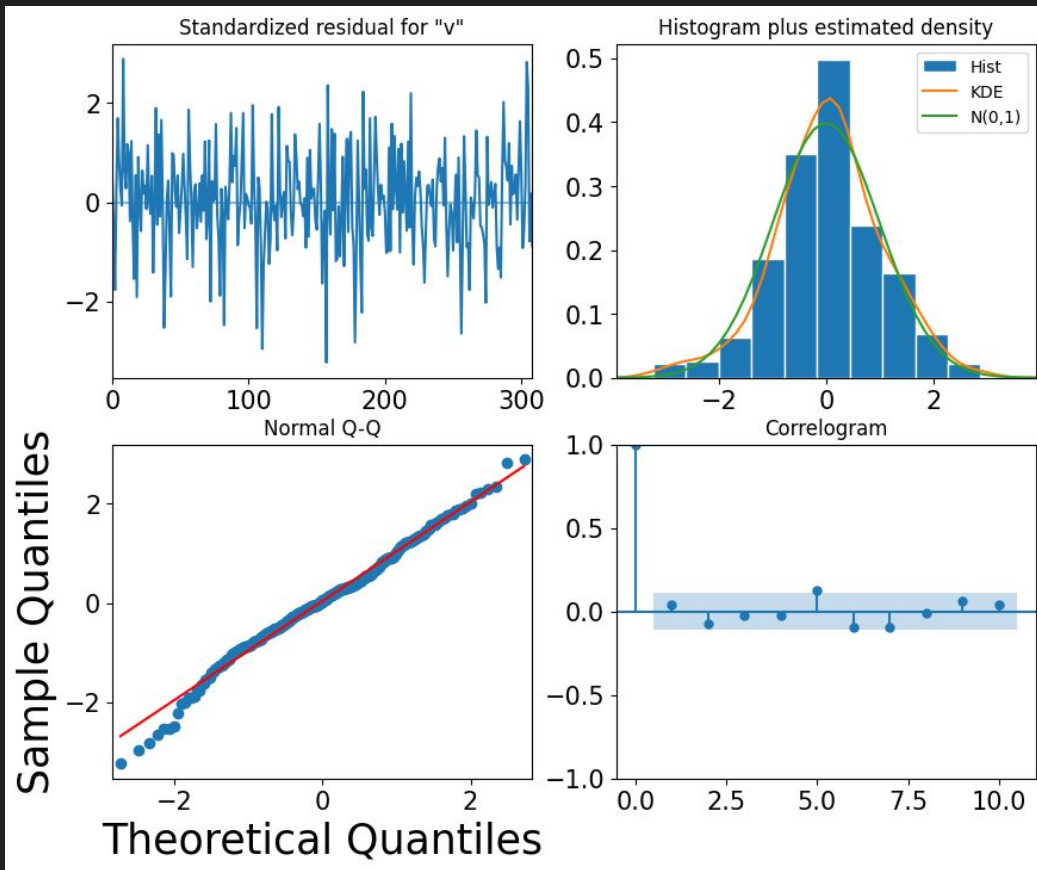
Log Likelihood -1684.040

AIC 3386.080

BIC 3419.680


Ljung-Box (L1) (Q) 0.59

Prob(Q) 0.44



Modelo ARIMA

Predicción



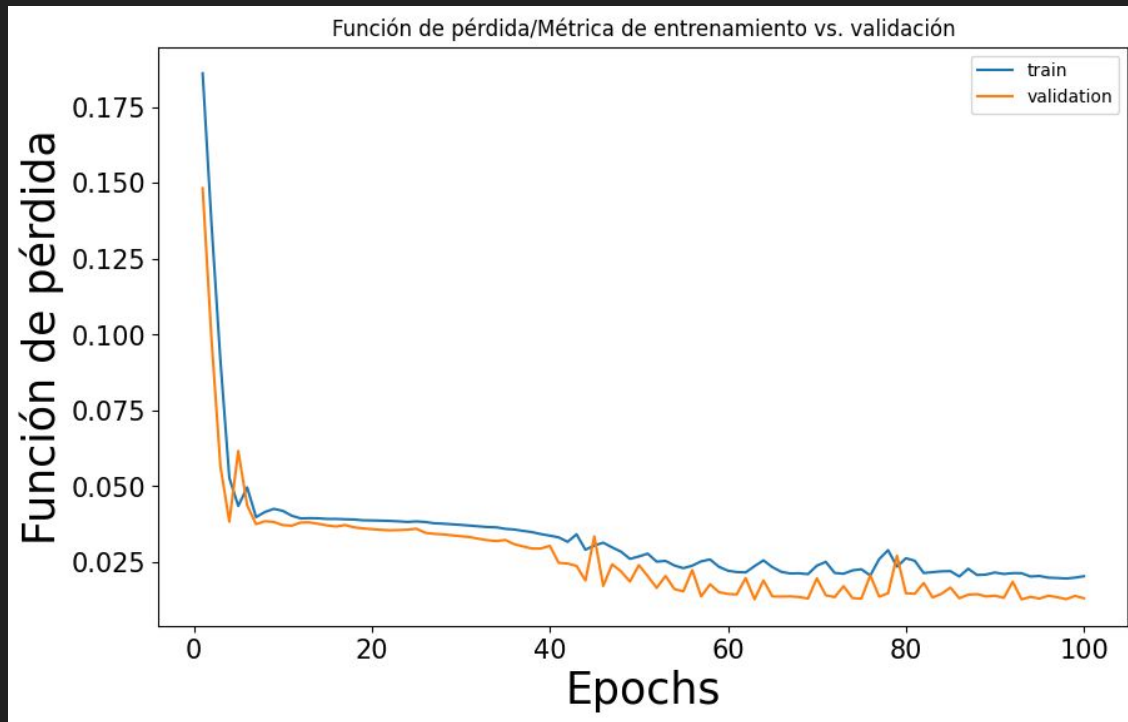
Red LSTM

Entrada de 2 ciclos

(entrada de 24 muestras)

50 bloques de
neuronas LSTM


Función de activación Relu



Red LSTM

Train Score: 66.75 RMSE

Test Score: 69.33 RMSE



Conclusiones

	AIC	BIC	RMSE
ARMA(1,2)	3811.276	3830.148	88.60
SARIMA(1,0,2)(3,1,3,12)	3421.922	3459.288	61.09
SARIMA(1,0,2)(1,1,2,12)	3386.080	3419.680	62.10
Red LSTM (50)			66.75